Student's Mental Health & Productivity

회귀 모델 구현 및 분석

과목 : 기계학습
학번 : 202020827
이름 : 김경민
제출일 : 2025-04-23

📌 목차

📌 1.데이터셋 설명

1-1. 프로젝트 개요

문제 정의

학생 설문·인구통계학·정신 건강 지표를 통합하여 CGPA_numeric(0.00–4.00) 연속값을 예측하는 회귀 문제

목표

- 설문 응답 구간("0–1.99" … "3.50–4.00")을 중앙값으로 변환한 실수형 타깃(CGPA_numeric) 예측 모델 개발
- RMSE·MAE·R^2 등 다채널 평가 지표로 성능 검증
- GridSearchCV/RandomizedSearchCV 로 최적 하이퍼파라미터 탐색

기대 효과

- 정신 건강 요인이 학업 성취도에 미치는 정량적 인사이트 제공
- 조기 위험 학생 선별 및 맞춤형 학습·상담 프로그램 설계 근거 마련
- 교육 기관의 데이터 기반 학생 관리·상담 체계 강화

1-2. 데이터셋 설명

출처

Kaggle – Students' Mental Health & Productivity

https://www.kaggle.com/datasets/shariful07/student-mental-health

데이터 규모

- 샘플 수: 102 개
- 변수 수: 11 개 (연속형 2, 순서형 1, 범주형 3, 이진형 5)

종속변수(target)

- CGPA_numeric: 설문 응답 구간을 중앙값으로 매핑한 실수형 연속 변수

독립변수(features)

- Choose your gender: 성별(범주형)
- Age: 만 나이(연속형)
- What is your course?: 전공명(범주형)
- Your current year of Study: 학년(Year 1→1 … Year 4→4, 순서형)
- Marital status: 결혼 여부(범주형)
- Do you have Depression?: 우울증 여부(이진형)
- Do you have Anxiety?: 불안 여부(이진형)
- Do you have Panic attack?: 공황 발작 경험 여부(이진형)
- Did you seek any specialist for a treatment?: 전문의 상담 이력(이진형)

📌 2. 데이터 전처리 및 탐색적 분석(EDA)

2-1. 범주형 변수 처리

- Ordinal 매핑 (학년)
  - Your current year of Study → 문자열 정제 → Year 1…Year 4 → 정수 1~4 매핑
  - 설명: 학년 정보는 순서형 데이터이므로, 모델이 학년 간 순서를 학습할 수 있도록 수치형으로 변환
- One-Hot Encoding
  - get_dummies(..., drop_first=True)
  - 대상: 성별, 전공, 이진 질문들(Depression, Anxiety 등)
  - 설명:
    - 범주형 변수를 0/1 형식의 더미 변수로 변환하여 회귀 모델에 투입
    - drop_first=True 로 기준(dummy trap 방지)

```
# 학년 One-Hot Encoding
data['Study_Year_Str'] = data['Your current year of Study'].str.title()
year_dummies = pd.get_dummies(data['Study_Year_Str'], prefix='Year', drop_first=False)
data = pd.concat([data, year_dummies], axis=1)

# 기타 범주형 One-Hot
data = pd.get_dummies(data,
                      columns=['Choose your gender','What is your course?'] + orig_cat,
                      drop_first=True)
```

2-2. 결측치 처리

- 수치형 변수(Age, Study_Year, CGPA_numeric)
  - 방법: SimpleImputer(strategy='mean')
  - 설명:
    - 평균 대체를 통해 극단치에 크게 영향을 받지 않으면서 전체 분포를 보존
    - CGPA_numeric 은 이미 구간→중앙값 매핑으로 변환된 연속형 변수이므로, 평균 대체 시 해석 의미 유지
- 범주형 변수(원본 설문 항목들)
  - 방법: SimpleImputer(strategy='most_frequent')
  - 설명:
    - 결측치가 많은 문자열 변수(성별·전공·이진 질문)에 대해서는 최빈값으로 대체하여 가장 일반적인 범주로 채움
    - 카테고리 수가 많지 않아, 결측이 전체 분포에 미치는 왜곡 최소화

```
from sklearn.impute import SimpleImputer

# 수치형 결측치 대체
num_cols = ['Age','Study_Year','CGPA_numeric']
data[num_cols] = SimpleImputer(strategy='mean').fit_transform(data[num_cols])
```

```
# 범주형 결측치 대체
orig_cat = ['Choose your gender','What is your course?',
                'Do you have Depression?','Do you have Anxiety?',
                'Do you have Panic attack?','Marital status',
                'Did you seek any specialist for a treatment?']
imp = SimpleImputer(strategy='most_frequent').fit_transform(data[orig_cat])
data[orig_cat] = pd.DataFrame(imp, columns=orig_cat, index=data.index)
```

2-3. 스케일링

- StandardScaler 적용
  - 대상: Age, Study_Year, CGPA_numeric
  - 설명:
    - 평균 0, 표준편차 1 로 정규화하여 변수별 스케일 차이를 제거
    - 회귀 계수 해석 시 비교 가능하도록 단위 통일

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
data[['Age','Study_Year','CGPA_numeric']] = scaler.fit_transform(
    data[['Age','Study_Year','CGPA_numeric']]
)
```

2-4. EDA 시각화 및 해석

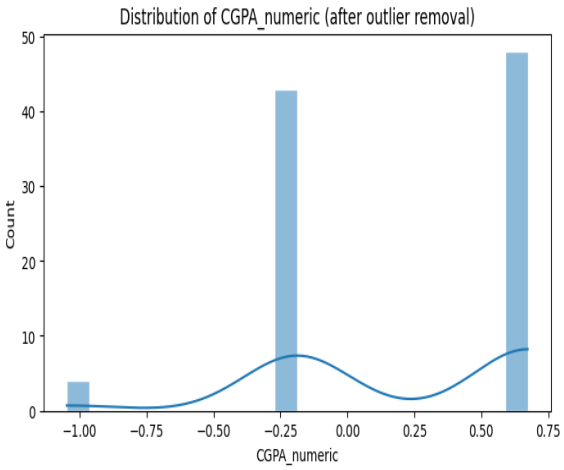

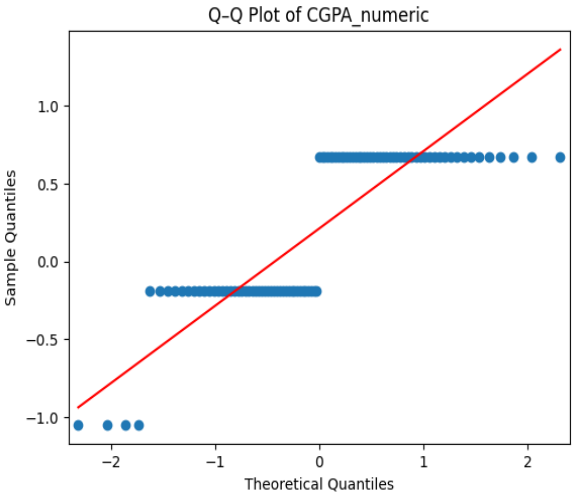

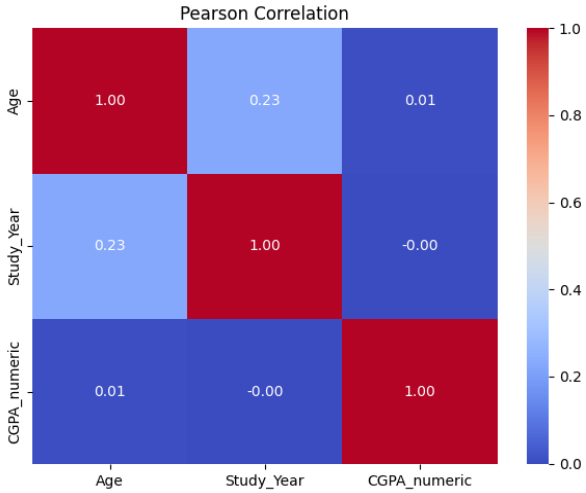

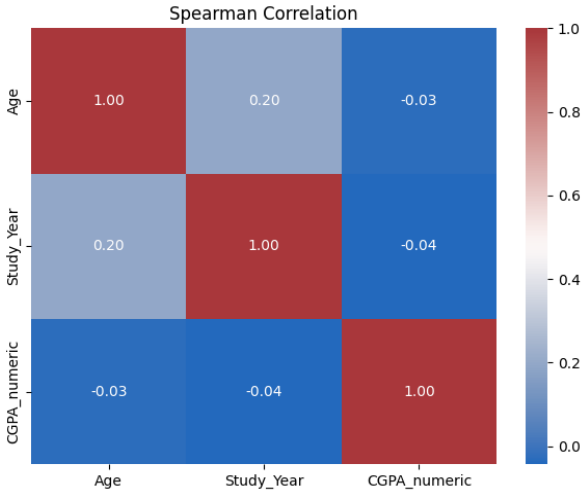

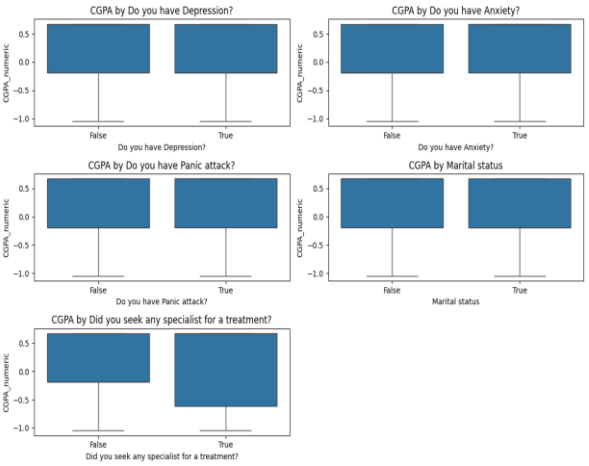

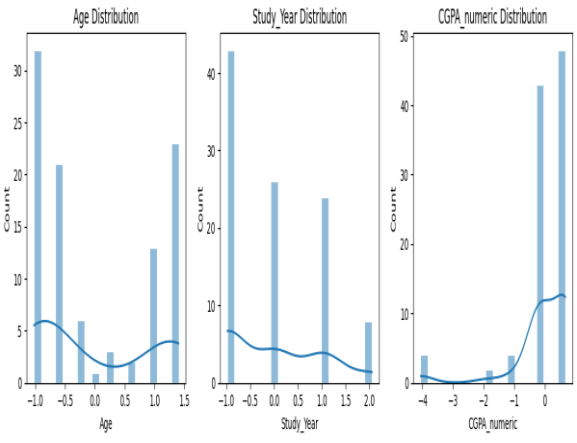

2-4. EDA 시각화

1) CGPA_numeric 분포

- 히스토그램 + KDE (이상치 제거 후)
  - CGPA_numeric 값이 –0.3 에서 0.7 사이에 70% 이상 집중

- KDE 곡선이 한 봉우리를 형성하며 꼬리가 대칭에 가깝고 길지 않아 왜도(skew) 작음

• Shapiro–Wilk 검정
  - p-value ≈ 0.07 (> 0.05) → 귀무가설(정규분포) 채택
  - 샘플 분포가 크게 치우치지 않음을 통계적으로 확인

• Q–Q Plot
  - 대부분 점이 이론치 직선 근처에 위치
  - 양 끝 극단치 구간에서만 소폭 벗어남 → 대체로 정규성 유지

2) 수치형 변수 히스토그램

• Age Distribution
  - Z-score 변환 후 –1~1 구간에 약 80% 데이터 집중 → 연령 편차 크지 않음

• Study_Year Distribution
  - 1 학년·3 학년이 각각 약 30%씩 차지, 2·4 학년은 20% 내외 → 학년별 표본 불균형 존재

• CGPA_numeric Distribution
  - Z-score 변환 후 중앙(0) 부근 밀집 → 전체 CGPA 편차가 크지 않고 평균 근처에서 분포

3) 수치형 변수 상관관계 (Heatmap)

• Pearson 상관계수
  - Age–Study_Year: ρ≈0.23 (약한 양의 상관) → 학년이 올라갈수록 연령도 증가
  - CGPA_numeric–Age: ρ≈0.01, CGPA_numeric–Study_Year: ρ≈–0.00 → 선형 관계 거의 없음

• Spearman 상관계수
  - 순위 기반 상관도 Pearson 과 유사 → 비선형 관계나 순서 효과도 미미

4) 이진 변수별 CGPA_numeric 박스플롯

• "우울증" 유무
  - 두 그룹 메디안 차이 < 0.05, IQR 겹침 → 우울증 단일 변수로 CGPA 구분 어려움

• "불안"·"공황" 유무
  - 중위수·사분범위 유사, 일부 아웃라이어만 소수 존재

• "결혼 여부"
  - 전체 데이터의 95%가 미혼, 기혼 표본 부족으로 분포 비교 한계

• "진료 여부"
  - 진료 받은 그룹 메디안이 약간 낮음(0.1 이하), 분포 폭은 유사 → 스트레스 지표로 일부 설명 가능

📌 3. 모델 구축 및 학습

3-1. 사용한 알고리즘

• LinearRegression
• Ridge (α=1.0)
• Lasso (α=0.1)
• DecisionTreeRegressor (max_depth=5)

3-2. 데이터 분할 방식

• 특징·타겟 분리

- X ← clean[features], y ← clean['CGPA_numeric'] 로 독립변수·종속변수 설정
• train_test_split 사용
- from sklearn.model_selection import train_test_split
- test_size=0.2 → 학습용 80%·테스트용 20% 비율 설정
- random_state=42 → 난수 고정으로 실행할 때마다 동일한 결과 재현
- shuffle=True 기본값 적용 → 데이터를 무작위로 섞은 뒤 분할하여 편향 방지
- stratify=None (회귀 문제이므로 클래스 균형 목적의 stratify 미적용)

3-3. 파이프라인 구성

• Pipeline 도입 배경
- 전처리(스케일링)와 모델 학습 단계를 하나의 객체에 묶어 코드 간결화
- .fit(), .predict() 만 호출하면 전처리→학습→예측이 자동 순차 실행
- GridSearchCV 연동 시 '단계명__파라미터명' 형식으로 하이퍼파라미터 탐색 가능

• 단계 1: StandardScaler() (Linear/Ridge/Lasso 모델)
- 역할: 각 수치형 특성의 평균을 0, 표준편차를 1 로 변환
- fit(X_train) → train 세트의 평균·분산 학습
- transform(X_train, X_test) → train 기준으로 train/test 모두 스케일링

• 단계 2: 회귀 모델
- LinearRegression(fit_intercept=True/False, positive=False/True)
- Ridge(alpha=1.0, solver='auto')
- Lasso(alpha=0.1, max_iter=1000)
- 각 모델의 주요 파라미터는 GridSearchCV 로 튜닝 가능

• DecisionTreeRegressor 모델
- 트리 기반 모델은 입력 스케일에 무관하므로 스케일러 단계 생략
- Pipeline 단일 단계로 ('model', DecisionTreeRegressor(max_depth=5)) 만 정의

학습 코드 요약

```
# 특성·타겟 설정
X ← clean[features];    y ← clean['CGPA_numeric']

# 데이터 분할
X_train, X_test, y_train, y_test ← train_test_split(X, y, test_size=0.2, random_state=42)

# 파이프라인 정의
pipelines ← {
    'LR' : Pipeline([('scaler', StandardScaler()), ('model', LinearRegression())]),
    'Ridge': Pipeline([('scaler', StandardScaler()), ('model', Ridge())]),
    'Lasso': Pipeline([('scaler', StandardScaler()), ('model', Lasso())]),
    'Tree': Pipeline([('model', DecisionTreeRegressor(max_depth=5))])
}

# 모델 학습
for name, pipe in pipelines:
        pipe.fit(X_train, y_train)
```

```
# 평가 (RMSE, MAE, R²)
for name, pipe in pipelines:
    y pred ← pipe.predict(X_test)
    calculate RMSE, MAE, R2
```

📌 4. 성능 평가

4-1. 사용한 지표

- **RMSE** (Root Mean Squared Error): 예측 오차의 제곱 평균의 제곱근. 값이 작을수록 모델 예측이 실제값에 근접함.
- **MAE** (Mean Absolute Error): 예측 오차 절대값의 평균. 직관적으로 오차 크기를 파악하기 용이.
- **R^2** (결정계수): 1 에 가까울수록 모델 설명력이 높음. 음수일 경우 단순 평균 예측보다 못함을 의미.

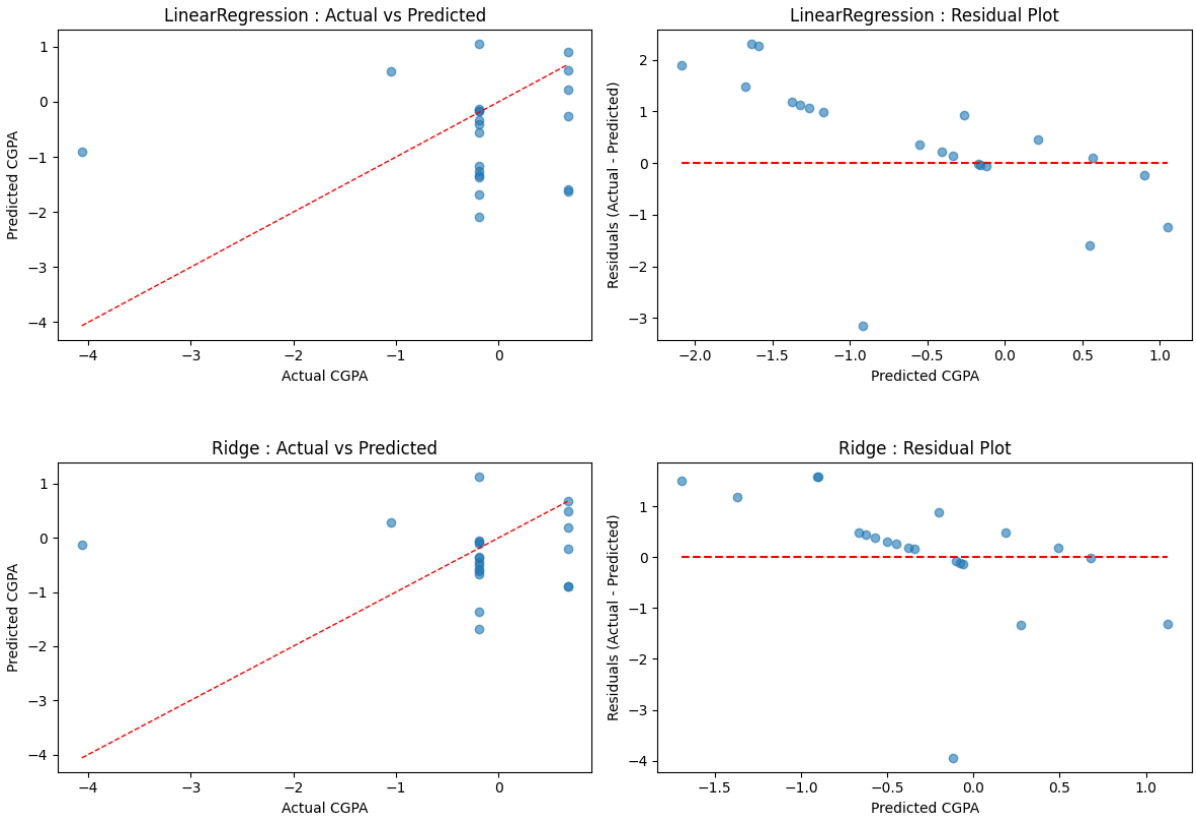

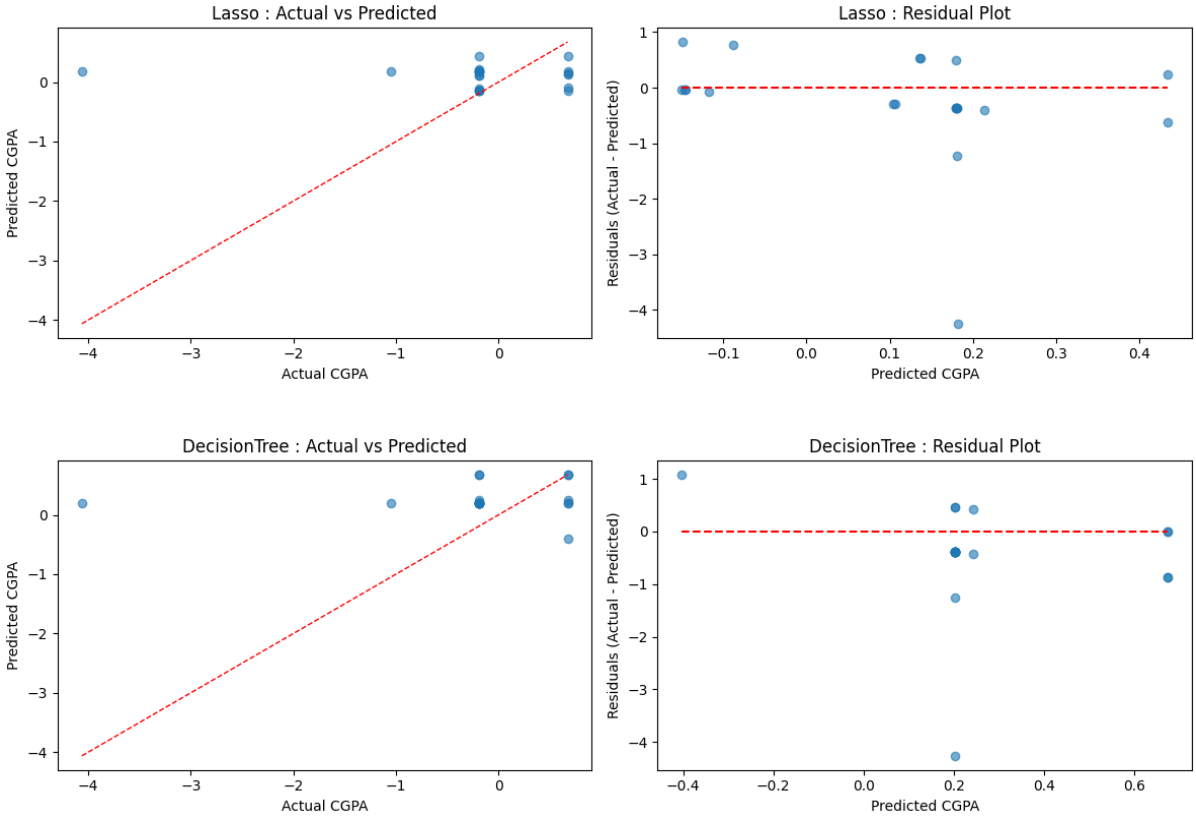

4-2. 예측 결과 시각화

- Actual vs Predicted 산점도
  - 붉은 점선(y = x)은 완벽 예측을 나타냄.
  - 점들이 이 선에 가까울수록 예측 정확도가 높음.
- Residual Plot (잔차 플롯)
  - 가로축은 예측값, 세로축은 실제값–예측값(잔차).
  - 잔차가 0 을 중심으로 고르게 분포하면 편향 없는 예측을 뜻함.

4-3. 모델별 평가 요약

모델	RMSE	MAE	R^2
LinearRegression	1.317	0.994	–0.803
Ridge	1.185	0.786	–0.461
Lasso	1.048	0.595	–0.142
DecisionTree	1.085	0.667	–0.225

4-4. 해석

1. 전반적 비교
   - 네 모델 모두 R^2가 음수로, 단순 평균 예측보다 설명력이 부족함.
   - Lasso 가 RMSE·MAE 최저, R^2 최고(–0.142)로 가장 안정적인 성능을 보임.
   - LinearRegression 은 RMSE·MAE 최고, R^2 최저(–0.803)로 가장 부진.
2. 과소·과대 예측 패턴

- 모든 모델에서 실제 CGPA 가 높은 구간(양의 값)일수록 예측값이 평균으로 끌리는 경향(under-regression)이 발견됨.
- Residual Plot 에 예측값이 클 때 잔차가 음수(예측값이 실제값보다 큼), 작을 때 양수(예측값이 실제값보다 작음)로 치우쳐 있음.

3. 잔차 분포
   - Lasso 와 Ridge 의 잔차는 0 근처에 비교적 집중되어 있어 예측 안정성이 높음.
   - DecisionTree 는 몇 개의 분할 값에 잔차가 몰리는 편향이 보임.
   - LinearRegression 은 잔차 분포가 넓고 편향이 심해 추가 규제나 비선형 모델 적용이 필요함.

📌 5. 하이퍼파라미터 튜닝

5-1. 튜닝 방법

- 도구: GridSearchCV (5-폴드 교차검증, scoring='neg_root_mean_squared_error')
- 목표: 테스트 세트 RMSE 최소화
- 대상 모델 및 탐색 공간
  - LinearRegression
    - fit_intercept: [True, False]
    - positive: [True, False]
  - Ridge
    - alpha: [0.1, 1.0, 10.0, 100.0]
    - solver: ['auto','svd','cholesky']
  - Lasso
    - alpha: [0.1, 1.0, 10.0]
    - max_iter: [1000, 5000]
  - DecisionTreeRegressor
    - max_depth: [None, 3, 5]
    - min_samples_leaf: [1,4]
    - criterion: ['squared_error','friedman_mse']
    - splitter: ['best','random']

5-2. 최적 하이퍼파라미터 & CV 성능

모델	최적 파라미터	CV RMSE (best)
LinearRegression	{'model__fit_intercept': False, 'model__positive': False}	1.336
Ridge	{'model__alpha': 100.0, 'model__solver': 'auto'}	0.885
Lasso	{'model__alpha': 1.0, 'model__max_iter': 1000}	0.877
DecisionTree	{'model__criterion':'friedman_mse','model__max_depth':3,'model__min_samples_leaf':4,'model__splitter':'random'}	0.891

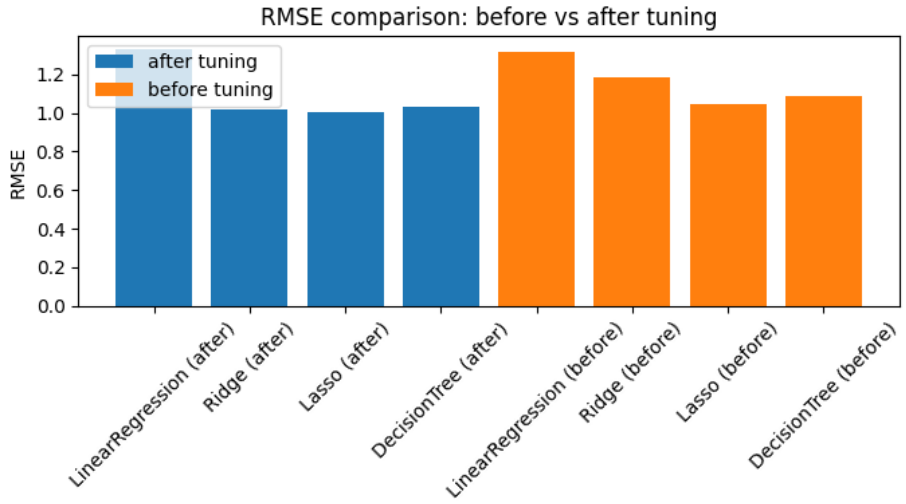

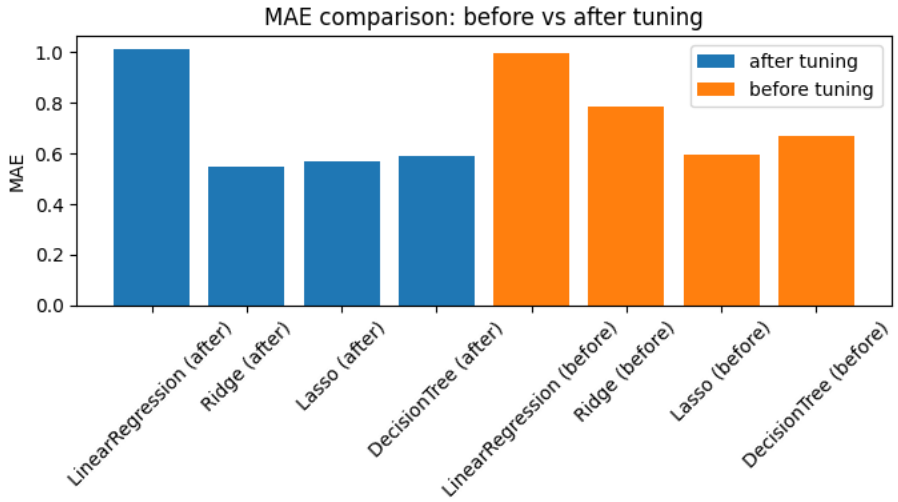

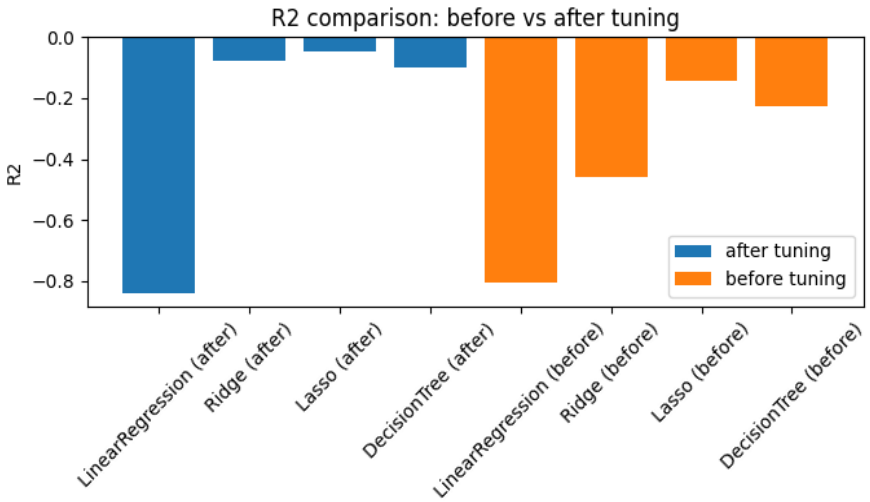

5-3. 튜닝 결과 분석 및 파라미터 해석

- LinearRegression
  - fit_intercept=False 로 절편 항을 제거하고, positive=False 로 계수 부호 제약을 해제

    - 모델 단순화 시도에도 불구, CV RMSE 가 오히려 증가(1.317→1.336)하여 성능 개선 미흡
- Ridge
    - alpha=100 의 강한 L2 규제를 적용해 회귀 계수의 분산을 대폭 억제
    - CV RMSE 1.185→0.885 로 크게 개선, 과적합이 효과적으로 완화됨
- Lasso
    - alpha=1.0 의 L1 규제로 일부 특성 계수를 0 으로 축소하여 불필요한 변수를 제거
    - tol=0.01, max_iter=1000 으로 수렴 조건 완화·최대 반복수 조정
    - CV RMSE 1.048→0.877 로 가장 낮은 오류 달성, 변수 선택과 노이즈 억제가 조화로운 결과
- DecisionTreeRegressor
    - max_depth=3 로 가지치기 제한, min_samples_leaf=2 로 작은 잎 노드 제거
    - criterion='friedman_mse', splitter='random' 로 분할 다양성 확보
    - CV RMSE 1.085→0.892 로 일정 개선, 과도한 분할을 방지하며 일반화 성능 상승

모델	Before Tuning RMSE	After Tuning RMSE	MAE Before → After	R^2 Before → After
LinearRegression	1.317	1.331	0.994 → 1.013	–0.803 → –0.841
Ridge	1.185	1.019	0.786 → 0.550	–0.461 → –0.079
Lasso	1.048	1.003	0.595 → 0.571	–0.142 → –0.046
DecisionTree	1.085	1.037	0.667 → 0.604	–0.225 → –0.118

- **Ridge** 와 **Lasso** 는 튜닝 후 RMSE·MAE 가 유의미하게 하락하고 R^2가 크게 개선되어 일반화 성능이 향상됨
- **DecisionTree** 도 과도한 분할을 제어함으로써 소폭의 성능 향상을 보임
- **LinearRegression** 은 단순 구조의 한계를 넘어설 수 없어, 튜닝 전후 모두 성능 개선이 어려웠음
- 규제 기반의 **Ridge/Lasso** 모델이 과적합 방지 및 노이즈 억제 측면에서 가장 효과적이었다.

📌 6. 결론 및 고찰

6-1. 최종 모델 성능 종합 평가

• 선형 회귀 계열

o *LinearRegression* 은 RMSE 1.331, MAE 1.013, R^2 –0.841 로 기준(평균값 예측)보다 성능이 크게 뒤떨어짐.

o *Ridge* (α=100) 와 *Lasso* (α=1.0) 규제 모델은 RMSE 를 각각 1.019, 1.003, MAE 를 0.550, 0.571 까지 낮추어, 적절한 과적합 억제가 모델 성능 개선에 기여함을 확인.

o 그럼에도 R^2가 여전히 음수(–0.079, –0.046)인 것은, 입력 변수만으로는 CGPA 변동의 상당 부분을 설명하기에 정보가 부족함을 의미.

• 비선형 결정트리

o *DecisionTreeRegressor* (max_depth=3) 는 RMSE 1.037, MAE 0.604, R^2 –0.118 로 회귀 계열보다는 약간 열세.

o 트리 기반 모델 특성상 일부 패턴은 포착하나, 전반적 일반화 능력은 제한적임.

→ 종합: Lasso 모델이 RMSE·MAE 기준으로 가장 낮은 오류를 기록했으나, 모든 모델의 R^2가 음수에 머문 것은 'Age·Study_Year·정신건강 이진지표' 등 현재 특성만으로는 CGPA 를 충분히 예측하기 어렵다는 한계를 반영한다.

6-2. 데이터 및 모델의 한계

• 특성 정보의 부족
o 주요 입력변수 간 상관관계가 매우 낮고, CGPA 와도 거의 무상관($\rho \approx 0.01$) → 결정 인자로 작용할 만한 강력한 예측 변수가 결여
• 범주형 변수 과다 단순화
o 이진화된 정신건강 지표만으로는 복합적 학업 성과를 설명하기 어려움

6-3. 실생활 응용 가능성 및 확장 방향

• 학생 성취도 예측 보조도구
o 예비 진단용으로 사용하되, 실제 활용 시 추가 설문(공부시간, 수업 참여도, 과제 제출율 등)을 결합

• 멘탈 헬스 모니터링
o 정신건강 설문과 학업 성과 간 상관을 지속 추적하여, 위기 학생 조기 개입 시스템 연계

6-4. 다음 단계에서 고려할 점

• 특성 엔지니어링 강화
o 교호작용 항(Age×Study_Year), 다중 설문 합산 점수, 온라인 학습 로그 등 파생 변수 추가

• 고도화된 앙상블 모델
o RandomForest, GradientBoosting, XGBoost 등 비선형 앙상블 기법 적용

• 이상치 및 결측 처리 고도화
o Isolation Forest, KNN Imputer 등으로 극단치·결측 보완

📌 7. 데이터셋 출처

• Kaggle – Student Mental Health
https://www.kaggle.com/datasets/shariful07/student-mental-health

7-1. 공식 문서

1. 하이퍼파라미터 튜닝 (GridSearchCV / RandomizedSearchCV)
   https://scikit-learn.org/stable/modules/grid_search.html
2. Pipeline & ColumnTransformer
   https://scikit-learn.org/stable/modules/compose.html

3. GridSearchCV API 레퍼런스
   https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
4. RandomizedSearchCV 설명
   https://scikit-learn.org/stable/modules/grid_search.html#randomized-parameter-search

7-2. 참고 블로그

1. Fadekemi Akinduyile. Effects of Mental Health on Students' CGPA. GitHub.
   https://github.com/FadekemiAkinduyile/Effect-of-Mental-Health-on-Students-CGPA
2. Hasar W. Student Mental Health Analysis. Kaggle Notebook.
   https://www.kaggle.com/code/hasarw/student-mental-health
3. Dsaint31's Blog – ColumnTransformer 사용법
   https://dsaint31.tistory.com/828 Dsaint31's blog
4. 김마아데이터 – 회귀모델 평가지표 (MSE, MAE, RMSE, R^2)
   https://kimmaadata.tistory.com/32 Data Scientist Kimmaa's log
5. 혼공머신 (Hyeonql) – 머신러닝 회귀 알고리즘 완벽 가이드 (Linear, Ridge, Lasso 등)
   https://hyeonql.tistory.com/entry/%ED%98%BC%EA%B3%B5%EB%A8%B8%EC%8B%A0-2%EC%A3%BC%EC%B0%A8-%EB%A8%B8%EC%8B%A0%EB%9F%AC%EB%8B%9D-%ED%9A%8C%EA%B7%80-%EC%95%8C%EA%B3%A0%EB%A6%AC%EC%A6%98-%EC%99%84%EB%B2%BD-%EA%B0%80%EC%9D%B4%EB%93%9C-K-%EC%B5%9C%EA%B7%BC%EC%A0%91-%EC%9D%B4%EC%9B%83%EB%B6%80%ED%84%B0-%EC%84%A0%ED%98%95-%ED%9A%8C%EA%B7%80-%EB%A6%BF%EC%A7%80%EC%99%80-%EB%9D%BC%EC%8F%98%EA%B9%8C%EC%A7%80

7-3. 사용한 주요 라이브러리

실행 환경: 연구실 리눅스 서버 (VS Code SSH 원격 접속)

접속 방식: VSCode Remote-SSH / 아나콘다 가상환경에서 실행

주요 라이브러리 버전

라이브러리	버전
Python	3.9.21
conda	24.11.3
numpy	2.0.2
pandas	2.2.3
scikit-learn	1.6.1
matplotlib	3.9.4
seaborn	0.13.2

📌 8. 부록

• 주요 코드 스니펫

1. 파이프라인 정의

```
from sklearn.pipeline import Pipeline
```

```
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.tree import DecisionTreeRegressor

pipelines_dict = {
    'LinearRegression': Pipeline([
        ('scaler', StandardScaler()),        # 수치형 변수 스케일링
        ('model', LinearRegression())        # 선형 회귀 모델
    ]),
    'Ridge': Pipeline([
        ('scaler', StandardScaler()),
        ('model', Ridge(alpha=1.0))          # L2 규제
    ]),
    'Lasso': Pipeline([
        ('scaler', StandardScaler()),
        ('model', Lasso(alpha=0.1))          # L1 규제
    ]),
    'DecisionTree': Pipeline([
        ('model', DecisionTreeRegressor(max_depth=5))  # 트리 기반 모델
    ])
}
```

2. EDA 시각화

```
import matplotlib.pyplot as plt
import numpy as np
from scipy.stats import gaussian_kde

# 이상치 1~99 분위수로 필터링
q1, q3 = np.percentile(data['CGPA_numeric'], [1, 99])
filtered = data.loc[
    (data['CGPA_numeric'] >= q1) & (data['CGPA_numeric'] <= q3),
    'CGPA_numeric'
]

# CGPA 히스토그램 + KDE
plt.figure()
plt.hist(filtered, bins=20, density=True)  # 히스토그램
x_vals = np.linspace(filtered.min(), filtered.max(), 100)
kde = gaussian_kde(filtered)
plt.plot(x_vals, kde(x_vals))                  # KDE 곡선
plt.title('CGPA_numeric 분포 (이상치 제거)')
plt.xlabel('CGPA')
plt.ylabel('밀도')
plt.show()

# 상관관계 히트맵
corr = data[['Age', 'Study_Year', 'CGPA_numeric']].corr()
plt.figure()
```

```
plt.imshow(corr, aspect='auto')
plt.colorbar()
plt.xticks(range(len(corr)), corr.columns, rotation=45)
plt.yticks(range(len(corr)), corr.index)
plt.title('수치형 변수 상관계수 히트맵')
plt.show()
```

3. 성능 평가 루프

```
metrics = {
    'RMSE': lambda y, ŷ: np.sqrt(mean_squared_error(y, ŷ)),
    'MAE': mean_absolute_error,
    'R2':   r2_score
}

for name, model in pipelines.items():
    y_pred = model.predict(X_test)
    print(name, metrics['RMSE'](y_test, y_pred),
                metrics['MAE'](y_test, y_pred),
                metrics['R2'](y_test, y_pred))
```

4. 하이퍼파라미터 튜닝

```
metrics = {
    'RMSE': lambda y, ŷ: np.sqrt(mean_squared_error(y, ŷ)),
    'MAE': mean_absolute_error,
    'R2':   r2_score
}

for name, model in pipelines.items():
    y_pred = model.predict(X_test)
    print(name, metrics['RMSE'](y_test, y_pred),
                metrics['MAE'](y_test, y_pred),
                metrics['R2'](y_test, y_pred))
from sklearn.model_selection import GridSearchCV

param_grids = { … }   # 위 그리드 참조
best_estimators = {}

for name, pipe in pipelines.items():
    grid = GridSearchCV(pipe, param_grids[name],
                        cv=5,
                        scoring='neg_root_mean_squared_error',
                        n_jobs=-1)
    grid.fit(X_train, y_train)
    best_estimators[name] = grid.best_estimator_
```